

Report

Studio sperimentale e costruzione di una pipeline per Aspect Term Extraction, Opinion Term Extraction e sentiment per aspetto

Daniela Nardone

Progetto per il corso di Sistemi Intelligenti per Internet

Abstract

Il progetto è stato sviluppato con l'obiettivo di studiare separatamente le principali componenti di una pipeline di analisi del sentiment basata sugli aspetti, confrontando più strategie per **Aspect Term Extraction (ATE)** e **Opinion Term Extraction (OTE)** prima di integrare i metodi migliori in una pipeline finale. Per l'ATE sono state confrontate architetture **RNN**, **LSTM** e **BiLSTM**, sia con embedding appresi casualmente sia con embedding GloVe pre-addestrati. Per l'OTE sono stati confrontati un metodo basato principalmente sul **POS tagging** ed un metodo basato sulle dipendenze sintattiche (**Dependency Parsing**). La pipeline finale è stata inizialmente valutata su un gold standard creato manualmente a partire da recensioni di ristoranti appartenenti al test set, di seguito è stata svolta una seconda valutazione su un gold standard creato, nuovamente, a mano di recensioni appartenenti al dominio dei laptop: in questa maniera si è potuta analizzare l'efficienza della pipeline su un dominio differente. Il confronto con risultati ABSA della letteratura mostra che il classificatore del sentiment raggiunge valori competitivi sui sottoinsiemi valutabili, ma la pipeline nel suo complesso resta fortemente limitata dalla generalizzazione dell'ATE e dalla propagazione degli errori tra gli stadi.

1. Introduzione

Il lavoro si presenta con un'iniziale analisi sperimentale delle varie componenti della pipeline: sono stati costruiti notebook distinti per ATE e OTE con l'obiettivo di confrontare diverse alternative, misurare i risultati e selezionare le configurazioni da riutilizzare nella pipeline finale. Infine, per ogni fase della pipeline sono state scelte le soluzioni che offrivano i migliori risultati.

L'**ATE** è stato trattato come un problema di sequence labeling con *etichette BIO*. Sono state confrontate tre tipologie di reti ricorrenti - *RNN*, *LSTM* e *BiLSTM* – con due diversi tipi di embedding.

L'**OTE** è stato affrontato con due procedure rule-based costruite sopra *spaCy* e *SentiWordNet*: una orientata alla ricerca di candidati tramite *POS tagging*, l'altra vincolata alle relazioni di dipendenza tra le differenti funzioni delle parole nella frase (*Dependency Parsing*). Dopo la scelta dei due metodi migliori, il risultato dell'OTE è stato utilizzato come input per un modulo di sentiment basato su *VADER*.

La valutazione finale è stata condotta in due scenari: il primo è **in-domain** e utilizza recensioni di ristoranti, coerenti con i dati su cui è stato addestrato il modello ATE. Il secondo è **cross-domain** e utilizza un gold standard di recensioni laptop, senza riaddestrare il modello, per verificare quali parti della pipeline dipendano maggiormente dal dominio. Questa seconda valutazione non è stata usata per selezionare nuovamente i modelli, ma esclusivamente come test di generalizzazione.

2. Dataset, preparazione dei dati e sperimentazione

2.1 Dataset restaurant

Il dataset restaurant utilizzato nei notebook contiene 3693 annotazioni di aspect term distribuite su 2019 frasi uniche. Ogni riga mette a disposizione la frase, l'aspect term, la polarità e gli offset carattere di inizio e fine dell'aspetto. Per l'ATE le annotazioni relative alla stessa frase sono state raggruppate, ottenendo una singola sequenza per frase con più possibili aspetti.

La tokenizzazione è stata effettuata con *TreebankWordTokenizer* e gli offset del dataset sono stati convertiti in etichette BIO. Nel notebook dedicato all'ATE il dataset è stato diviso con seed 42 in 1615 frasi di training, 202 di validation e 202 di test; in termini di aspect term, gli split contenevano rispettivamente 2975, 330 e 385 aspetti. Questa separazione è stata mantenuta per il confronto tra le architetture, così da rendere le metriche direttamente confrontabili.

2.2 Gold standard manuale per OTE e pipeline

Per misurare l'OTE e la pipeline integrata è stato utilizzato un gold standard manuale di 100 annotazioni restaurant, ognuna composta da *sentence*, *aspectTerm*, *opinionPhrase* e *polarity*.

2.3 Criterio di selezione dei metodi

Le scelte non sono state effettuate sulla base di una preferenza a priori per una determinata architettura. Per l'ATE il criterio principale è stato l'F1 sul test set, osservando anche precision e recall. Per l'OTE sono state considerate sia una misura di successo a livello di esempio sia precision, recall e F1 sulle opinion phrase normalizzate; è stata privilegiata la soluzione con F1 e precisione superiori, anche se produceva meno predizioni complessive. La pipeline finale è stata quindi costruita riutilizzando la **BiLSTM con embedding GloVe** e l'estrazione **dependency-based**.

3. Studio dell'Aspect Term Extraction (ATE)

3.1 Configurazioni analizzate

Nel notebook ATE sono state implementate sei configurazioni: RNN, LSTM e BiLSTM con embedding inizializzati casualmente, e le stesse tre architetture con embedding GloVe 6B da 300 dimensioni. Per i modelli pre-addestrati gli embedding erano aggiornabili durante il training; RNN e LSTM utilizzavano hidden size 256, mentre la BiLSTM produceva una rappresentazione bidirezionale di dimensione complessiva 512 prima del livello lineare. È stato utilizzato dropout 0,5 nelle versioni pre-addestrate e nella BiLSTM casuale.

Tutti i modelli sono stati addestrati con *Adam*, *learning rate 0,0005*, *cross-entropy con indice padding pari a 0* ed *early stopping con patience 4*. La selezione del checkpoint migliore è stata guidata dall'F1 sul validation set. L'evaluation finale è stata calcolata con *seqeval* sulle sequenze BIO, ovvero a livello di entità estratte.

3.2 Risultati con embedding casuali

Modello	Precision	Recall	F1
RNN	0,7297	0,6519	0,6886
LSTM	0,6899	0,6182	0,6521
BiLSTM	0,7927	0,6753	0,7293

Tabella 1. Risultati ATE con embedding appresi casualmente.

Tra i modelli con embedding casuali, la BiLSTM è risultata nettamente la configurazione migliore: F1 0,7293 contro 0,6886 della RNN e 0,6521 della LSTM. Il vantaggio deriva soprattutto dalla precisione, pari a 0,7927, mentre il recall rimane più contenuto a 0,6753. Già in questa fase la BiLSTM risultava potenzialmente essere la miglior scelta.

3.3 Risultati con GloVe pre-addestrato

Modello	Precision	Recall	F1
RNN + GloVe	0,6861	0,7039	0,6949
LSTM + GloVe	0,7150	0,7299	0,7224
BiLSTM + GloVe	0,7595	0,7299	0,7444

Tabella 2. Risultati ATE con embedding GloVe 300d.




Figura 1. Confronto dell'F1 tra embedding casuali e pre-addestrati.

L'introduzione di GloVe produce un miglioramento rilevante soprattutto per LSTM e BiLSTM. La LSTM passa da F1 0,6521 a 0,7224, mentre la BiLSTM raggiunge il valore più alto dell'intero studio, **0,7444**. La RNN migliora solo marginalmente, da 0,6886 a 0,6949. La BiLSTM + GloVe mantiene inoltre un equilibrio migliore tra precisione (0,7595) e recall (0,7299) rispetto alla corrispondente versione con embedding casuali.




Figura 2. Precision, recall e F1 delle configurazioni ATE con GloVe.

3.4 Scelta finale per l'ATE

La **BiLSTM con GloVe** è stata scelta per la pipeline perché presenta il miglior F1 tra tutte le configurazioni e non dipende da un vantaggio ottenuto solo su una singola metrica.

4. Studio dell'Opinion Term Extraction (OTE)

4.1 Metodo POS tagging

Il primo metodo OTE analizza ogni frase con spaCy, individua la posizione dell'aspect term e cerca candidati opinion tra aggettivi, verbi e nomi. I candidati vengono filtrati mediante una lista di stop word specifiche e *SentiWordNet*; quando SentiWordNet non contiene un lemma, gli aggettivi vengono comunque mantenuti come possibili opinion word. I candidati vengono ordinati per distanza dal centro dell'aspetto e vengono restituite al massimo le due opinion phrase più vicine. La phrase expansion incorpora modificatori, negazioni e complementi rilevanti.

Applicato alle 3693 annotazioni restaurant, il metodo POS tagging produce almeno una opinion phrase in 3613 casi, pari al 97,83% del dataset. Questa elevata copertura si traduce però in un numero consistente di falsi positivi: sul gold standard di 100 esempi ottiene 89 true positive, 100 false positive e 16 false negative, per precision 0,4709, recall 0,8476 e F1 0,6054. A livello di esempio, 68 annotazioni su 100 sono state considerate corrette.

4.2 Metodo Dependency Parsing

Il secondo metodo limita la ricerca ai token sintatticamente collegati all'aspect term: figli dell'aspetto, head dell'aspetto e figli dell'head. Tra questi candidati vengono considerati *ADJ*, *VERB* e *ADV* che superano lo stesso filtro lessicale del metodo POS-based. Le opinion phrase vengono poi ampliate con le stesse regole e scartate quando superano quattro token. Infine i candidati sono ordinati per distanza.

La procedura dependency-based produce almeno una opinion phrase in 2373 casi su 3693, cioè il 64,26%. La copertura è quindi molto inferiore al 97,83% del metodo POS, ma il numero di falsi positivi diminuisce nettamente. Sul gold standard si osservano 71 true positive, 45 false positive e 34 false negative, con precision 0,6121, recall 0,6762 e F1 0,6425. La misura di accuratezza per esempio è 56%, inferiore al 68% del POS tagging, ma la valutazione a livello di opinion term mostra una qualità complessiva maggiore.

Metodo	Copertura su 3693	Precision	Recall	F1	Successo esempi
POS-based	97,83%	0,4709	0,8476	0,6054	68%
Dependency-based	64,26%	0,6121	0,6762	0,6425	56%

Tabella 3. Confronto delle due strategie OTE.




Figura 3. Precision, recall e F1 per POS-based e Dependency-based OTE.

4.3 Decisione sul metodo OTE

Per la pipeline finale è stato scelto il **Dependency Parsing**: la decisione è motivata dal fatto che la pipeline richiede non solo di produrre una opinion phrase, ma di associarla correttamente all'aspetto. Il metodo POS tagging massimizza la copertura e il recall, ma genera molti candidati estranei e presenta precision inferiore a 0,5. Il metodo Dependency-based riduce invece i falsi positivi, porta la precisione a 0,6121 e ottiene l'F1 più alto, 0,6425. Poiché gli errori OTE si propagano direttamente al sentiment, è stato considerato preferibile ridurre la copertura a favore di associazioni più selettive e corrette.

5. Costruzione e valutazione della pipeline finale

5.1 Integrazione dei moduli selezionati

La pipeline finale riutilizza la BiLSTM con embedding GloVe per estrarre gli aspect term dalle frasi. Per ogni aspetto predetto viene eseguita la funzione Dependency Parsing dell'OTE. Le opinion phrase risultanti vengono quindi passate a VADER; per ciascuna phrase viene memorizzato il compound score e la relativa classe *positive*, *negative* o *neutral* usando le soglie standard $\pm 0,05$. Quando un aspetto ha più opinion phrase, la polarità finale è ottenuta dalla media dei compound score. Se non viene estratta alcuna opinion phrase, il sentiment per quell'aspetto rimane non disponibile.

L'evaluation ATE/OTE utilizza una tecnica di matching esatto dopo normalizzazione di sentence, aspect term e opinion phrase. Il successo ATE indica che l'aspetto gold è presente tra quelli predetti; l'opinion coverage misura se almeno una opinion gold è stata recuperata quando l'ATE è corretto; la copertura end-to-end richiede invece il recupero completo delle opinion gold. È stata inoltre calcolata una misura più severa a livello di sentence-aspect-opinion, con precision, recall e F1 su insiemi di coppie.

5.2 Risultati sul dominio restaurant

Fase	Metrica	Score
ATE	Success Rate	0,8333 (83,33%)
ATE → OTE	Opinion Coverage ATE correct	0,7333 (73,33%)
ATE → OTE	End-to-End Coverage	0,6111 (61,11%)
Aspect-Opinion Pair	Precision	0,4400
Aspect-Opinion Pair	Recall	0,6111
Aspect-Opinion Pair	F1	0,5116
Sentiment	Coverage ATE correct	0,8667 (86,67%)
Sentiment	Accuracy	0,8462 (84,62%)
Sentiment	Macro Precision	0,8000
Sentiment	Macro Recall	0,7778
Sentiment	Macro F1	0,7047

Tabella 4. Risultati della pipeline finale su restaurant.

Nel notebook finale il gold standard è stato intersecato con il test split dell'ATE: solo 18 annotazioni appartenevano effettivamente alle frasi del test set, pertanto tutte le metriche finali restaurant che coinvolgono ATE, OTE e sentiment sono riferite a queste istanze. Sulle 18 annotazioni gold presenti nel test split, 15 aspetti vengono riconosciuti correttamente, corrispondenti a un successo ATE dell'83,33%. Tra questi casi, l'OTE recupera almeno una opinion gold nel 73,33% delle istanze. Considerando l'intera catena e richiedendo che tutte le opinion gold siano coperte, il successo scende al 61,11%. La valutazione a coppie evidenzia inoltre 11 true positive, 14 false positive e 7 false negative, con F1 0,5116.

L'analisi degli errori ATE/OTE suddivide le 18 istanze in 11 successi completi (61,11%), 4 OTE failure (22,22%) e 3 ATE failure (16,67%). Il risultato mostra che, nel dominio di training, il principale stadio di degradazione non è l'ATE ma l'associazione dell'opinion term. Ciò è coerente con la maggiore difficoltà dell'OTE osservata anche nel notebook separato.

5.3 Valutazione ed error analysis del sentiment

Delle 15 istanze con aspect term corretto, 13 ricevono una predizione di sentiment, per una coverage dell'86,67%. Su queste 13 istanze l'accuracy è 84,62% e il Macro-F1 è 0,7047; il classification report mostra F1 0,95 per positive, 0,50 per negative e 0,67 per neutral. La classe positiva è nettamente prevalente nel piccolo sottoinsieme valutabile, con 9 esempi su 13.

L'error analysis mette in evidenza limiti diversi. Per l'aspetto 'Halibut', l'OTE estrae correttamente 'too salty', ma VADER assegna compound score 0,0 e quindi neutral, mentre il gold è negative: l'errore è attribuibile al lessico del sentiment analyzer. Per 'dessert', invece, l'opinion phrase predetta è "n't waste poor", che combina materiale riferibile a segmenti diversi della frase e porta VADER a una polarità positiva; in questo caso l'origine principale è l'associazione OTE.

6. Valutazione cross-domain su recensioni laptop

6.1 Impostazione

Per verificare la robustezza della pipeline, lo stesso modello ATE addestrato sui ristoranti è stato applicato a un gold standard laptop composto da 276 annotazioni. Il dataset laptop non è stato usato per il training, per il tuning o per la selezione delle regole OTE. La valutazione rappresenta quindi uno scenario con dominio totalmente differente.

Per ciascuna annotazione erano disponibili *sentence*, *aspectTerm*, *opinionPhrase* e *polarity*; il matching e le metriche sono stati calcolati con le stesse funzioni utilizzate sul gold standard sul dataset restaurant.

6.2 Risultati

Fase	Metrica	Restaurant	Laptop
ATE	Success Rate	0,8333	0,3261
ATE → OTE	Opinion Coverage ATE correct	0,7333	0,6556
ATE → OTE	End-to-End Coverage	0,6111	0,2138
Aspect-Opinion Pair	F1	0,5116	0,2830
Sentiment	Coverage ATE correct	0,8667	0,8333
Sentiment	Accuracy	0,8462	0,8800
Sentiment	Macro F1	0,7047	0,8136

Tabella 5. Confronto tra valutazione restaurant e cross-domain laptop.




Figura 4. Confronto delle metriche della pipeline nei due domini.

Il risultato più evidente è il crollo dell'ATE: il success rate passa dall'83,33% al 32,61%. Su 276 annotazioni laptop, 186 sono classificate come ATE failure, 59 come complete success ATE→OTE e 31 come OTE failure. La copertura end-to-end scende di conseguenza al 21,38%. Anche l'F1 delle coppie aspect-opinion cala da 0,5116 a 0,2830; sul laptop sono stati misurati 59 true positive, 82 false positive e 217 false negative.

L'OTE presenta invece una degradazione più contenuta quando è condizionato a un ATE corretto: l'opinion coverage passa dal 73,33% al 65,56%. Questo comportamento suggerisce che la strategia dependency-based sfrutta relazioni linguistiche più trasferibili tra domini rispetto al vocabolario e ai pattern appresi dall'ATE: ciò significa che il problema del cross-domain è relativo principalmente all'estrazione dell'aspetto.

Il sentiment mantiene una coverage molto simile (86,67% restaurant contro 83,33% laptop) e, sui casi validi, ottiene 88,00% di accuracy e Macro-F1 0,8136. Il risultato è superiore a quello restaurant, ma vengono valutate 75 predizioni di sentiment su 90 aspect term correttamente riconosciuti, mentre tutti gli ATE failure sono esclusi, pertanto la metrica descrive solo la qualità della predizione del sentiment quando la pipeline è riuscita a raggiungere la fase, appunto, di sentiment analysis.

6.3 Interpretazione cross-domain

L'esperimento laptop è particolarmente utile perché separa l'effetto del dominio sui moduli. La BiLSTM è stata addestrata solo sulle recensioni restaurant e tende quindi a riconoscere con maggiore affidabilità pattern lessicali e contestuali tipici di quel dominio. Nel passaggio ai laptop aumenta notevolmente il numero di aspect term non riconosciuti. OTE e VADER, invece, sono procedure meno dipendenti dal training restaurant: per questo motivo le loro metriche condizionate decadono meno o, nel caso del sentiment, migliorano sul sottoinsieme valutato.

7. Confronto con metodi ABSA della letteratura

7.1 Protocollo del confronto

Il confronto con la letteratura per il metodo ABSA è limitato alla classificazione della polarità per un aspect term già noto. I risultati di riferimento sono tratti da lavori che utilizzano i dataset SemEval-2014 Laptop e Restaurant: sono riportati ATAE-LSTM di Wang et al. (2016), BERT-SPC e LCF-BERT nella valutazione di Zeng et al. (2019).

Metodo	Laptop Accuracy	Restaurant Accuracy	Nota
ATAE-LSTM	68,70%	77,20%	Aspect-level sentiment classification
BERT-SPC	80,25%	85,98%	BERT con aspect/sentence pair
LCF-BERT (CDW)	82,45%	87,14%	Local Context Focus, miglior variante riportata
Pipeline proposta*	88,00%	84,62%	Solo casi con ATE corretto e sentiment disponibile

Tabella 6. Confronto indicativo con risultati ABSA su SemEval-2014.




Figura 5. Accuracy del sentiment: confronto indicativo con modelli ABSA pubblicati. *Metriche non direttamente comparabili.

7.2 Discussione sul confronto

Sul subset restaurant valutabile, l'accuracy della pipeline (84,62%) è superiore al valore riportato per ATAE-LSTM (77,20%), vicina a BERT-SPC (85,98%) e inferiore a LCF-BERT CDW (87,14%). Sul gold laptop, la pipeline raggiunge 88,00% sui 75 casi con aspetto corretto e sentiment disponibile, valore che risulta essere superiore ai tre casi presi in considerazione; è importante tenere però in conto che la pipeline proposta è più selettiva e scarta sia gli ATE failure sia i casi in cui l'OTE non produce materiale sufficiente per VADER.

Il confronto più utile è quindi qualitativo. I modelli ABSA della letteratura ottengono un'accuracy elevata quando ricevono direttamente l'aspetto target e apprendono il sentiment usando il contesto della frase. La pipeline proposta dimostra che un metodo lessicale leggero può ottenere buoni risultati una volta raggiunta correttamente la fase di sentiment, ma la sua efficacia globale dipende dalla capacità di estrarre l'aspetto e di associare una opinion phrase adeguata.

8. Conclusioni e limitazioni

Il progetto ha raggiunto l'obiettivo principale di analizzare separatamente ATE e OTE, selezionare i metodi migliori sulla base dei risultati e verificarne il comportamento quando vengono concatenati. Per l'ATE, il confronto tra sei configurazioni ha mostrato che la BiLSTM con embedding GloVe è la soluzione più efficace, con F1 0,7444 nel notebook comparativo. Per l'OTE, il metodo dependency-based è stato preferito al POS tagging nonostante la minore copertura, perché offre precisione e F1 superiori e riduce i falsi positivi.

L'integrazione di questi due moduli con VADER ha prodotto, sul sottoinsieme restaurant, 83,33% di ATE success, 73,33% di OTE coverage, 61,11% di successo ATE→OTE e 84,62% di accuracy del sentiment sui casi validi.

Il test sul dataset laptop ha fatto emergere che la pipeline non è totalmente capace di lavorare fuori dominio: L'ATE scende al 32,61%, mentre l'OTE dato un ATE corretto resta al 65,56% e il sentiment raggiunge 88,00% di accuracy. Il comportamento conferma che la parte più sensibile al dominio è il modello sequence-labeling addestrato sulle recensioni restaurant; la procedura dependency-based e il sentiment lessicale risultano più trasferibili, pur restando dipendenti dalla correttezza degli stadi precedenti.

8.1 Limitazioni

Il progetto presenta alcune limitazioni che devono essere considerate nell'interpretazione dei risultati ottenuti. In primo luogo, il gold standard utilizzato per la valutazione sul dominio restaurant ha dimensioni piuttosto ridotte. Delle 100 annotazioni manuali complessivamente disponibili, soltanto 18 appartengono alle frasi presenti nel test split e possono quindi essere utilizzate per una valutazione coerente.

Anche il metodo selezionato per l'OTE introduce alcune limitazioni. L'approccio è rule-based e dipende dall'analisi sintattica effettuata da spaCy e dalle informazioni fornite da SentiWordNet. Eventuali errori nel dependency parsing possono quindi propagarsi all'estrazione e all'associazione degli opinion term. Il problema risulta particolarmente evidente in presenza di strutture sintattiche più complesse, coordinazioni o opinion phrase discontinue.

Limiti analoghi sono presenti nella fase di sentiment analysis. VADER viene applicato alle opinion phrase precedentemente estratte e, di conseguenza, non dispone necessariamente dell'intero contesto della frase originale. Alcune espressioni possono pertanto ricevere una polarità diversa da quella attesa nel dominio specifico.

Inoltre, la valutazione cross-domain sui laptop evidenzia una limitazione importante relativa alla capacità di generalizzazione dell'ATE. Il modello utilizzato nella pipeline finale è stato addestrato esclusivamente sul dominio restaurant e non è stata effettuata alcuna procedura di training multi-domain.

Infine, un'ulteriore difficoltà riguarda la natura stessa dell'OTE: per ogni aspect term presente in una frase non è infatti possibile individuare una opinion phrase esplicita e, dunque, delimitata. In alcuni casi il giudizio nei confronti di un aspetto emerge dal significato complessivo della frase, da un'espressione più articolata oppure da informazioni contestuali, senza essere riconducibile a uno specifico termine valutativo. Questa caratteristica introduce una certa ambiguità sia nella costruzione del gold standard sia nella valutazione automatica dell'OTE.

8.2 Sviluppi possibili

Gli sviluppi più naturali, mantenendo la stessa impostazione sperimentale, sono: ampliare il gold restaurant e bilanciare le polarità. Inoltre, potrebbe risultare utile introdurre un ATE addestrato su più domini e migliorare la fase di OTE, anche gestendo in modo esplicito coordinazioni e negazioni.

Bibliografia

- [1] Y. Wang, M. Huang, X. Zhu, L. Zhao, 'Attention-based LSTM for Aspect-level Sentiment Classification', 2016.
- [2] B. Zeng, H. Yang, R. Xu, W. Zhou, X. Han, 'LCF: A Local Context Focus Mechanism for Aspect-Based Sentiment Classification', 2019.